

	VICERRECTORADO DOCENTE	Código: GUIA-PRL-001
	CONSEJO ACADÉMICO	Aprobación: 2016/04/06
Formato: Guía de Práctica de Laboratorio / Talleres / Centros de Simulación		

		PRÁCTICA DE LABORATORIO	
CARRERA: COMPUTACION		ASIGNATURA: COMPUTACION PARALELA	
NRO. PRÁCTICA:	5	TÍTULO PRÁCTICA: Desarrollo de un algoritmo en paralelo para procesar datos usando MPI con un clúster de computadoras	
OBJETIVOS			
Diseñar e implementar aplicaciones en paralelo usando las principales tecnologías			
INSTRUCCIONES	Objetivo de la práctica		
	Implementar una solución de computación paralela distribuida utilizando el paradigma de paso de mensajes (MPI), donde un nodo máster coordina el entrenamiento de modelos de Machine Learning ejecutados en dos nodos hijos, dentro de un clúster de hasta tres computadoras, y consolida los resultados para su visualización en una interfaz gráfica (GUI).		
	Contexto y escenario del problema		
	Se dispone de un clúster de computadoras compuesto por:		
	1 Nodo Máster (rank 0) 2 Nodos Hijos (rank 1 y rank 2)		
	Cada nodo se ejecuta como un proceso independiente MPI utilizando mpi4py, bajo el modelo SPMD (Single Program, Multiple Data).		
	El sistema simula un escenario real de entrenamiento distribuido de modelos de NLP, donde:		
	- El nodo máster: - Selecciona el dataset - Define los parámetros de entrenamiento - Envía los datos y configuraciones a los nodos hijos - Recibe métricas y resultados - Presenta los resultados en una GUI - Los nodos hijos: - Reciben el dataset y los parámetros - Entrenan un modelo de Machine Learning de forma independiente - Devuelven métricas y resultados al nodo máster		
	Problema a resolver (NLP)		
	Se desea resolver un problema de Procesamiento de Lenguaje Natural (NLP), por ejemplo:		
	- Clasificación de sentimientos - Clasificación de texto - Detección de spam		

	VICERRECTORADO DOCENTE	Código: GUIA-PRL-001
	CONSEJO ACADÉMICO	Aprobación: 2016/04/06
Formato: Guía de Práctica de Laboratorio / Talleres / Centros de Simulación		

- Análisis de opiniones
- Clasificación temática

⚠ El problema específico queda a elección del estudiante, siempre que cumpla con las condiciones descritas a continuación.

Dataset

El dataset también es elegido por los estudiantes, con las siguientes restricciones mínimas:

- Debe ser un dataset de texto (NLP)
- Debe contener:
 - Una columna de texto
 - Una columna de etiquetas/clases
- Puede provenir de:
 - Kaggle
 - HuggingFace Datasets
 - Dataset propio
- Ejemplos válidos:
 - IMDb Reviews
 - SMS Spam Collection
 - Twitter Sentiment Dataset
 - Noticias clasificadas por categoría

⚠ El nodo máster es responsable de cargar el dataset y enviarlo a los nodos hijos mediante MPI (bcast o send).

Modelos de Machine Learning

Cada nodo hijo debe entrenar un modelo diferente.

Los modelos son libres, pero deben ser modelos clásicos de ML, por ejemplo:

- Naive Bayes
- Logistic Regression
- Support Vector Machine (SVM)

Ejemplo de asignación:

- Nodo hijo 1 (rank 1): Modelo A
- Nodo hijo 2 (rank 2): Modelo B

Interfaz Gráfica (GUI)

El nodo máster debe incluir una GUI que muestre:

- Modelo entrenado por cada nodo
- Métricas de evaluación
- Tiempo de entrenamiento por nodo
- Comparación visual entre modelos

La GUI no debe ejecutarse en los nodos hijos.

Ejecución del sistema

La aplicación debe ejecutarse en un clúster de computadoras interconectadas a través de una red local (LAN), utilizando el modelo de paso de mensajes (MPI).

	VICERRECTORADO DOCENTE	Código: GUIA-PRL-001
	CONSEJO ACADÉMICO	Aprobación: 2016/04/06
Formato: Guía de Práctica de Laboratorio / Talleres / Centros de Simulación		

	Cada computadora del clúster ejecutará un proceso MPI independiente, cumpliendo los siguientes roles: • Nodo máster (rank 0): ○ Ejecuta la lógica de coordinación, distribución del dataset y parámetros de entrenamiento, recepción de resultados y visualización mediante la interfaz gráfica (GUI). • Nodos hijos (rank 1 y rank 2): ○ Ejecutan el entrenamiento de los modelos de Machine Learning asignados, reciben datos y parámetros desde el nodo máster y envían los resultados de vuelta. ⚠ No se permite la ejecución local en una sola computadora simulando múltiples procesos. La práctica debe ejecutarse en un entorno real de clúster, con computadoras físicas o virtuales conectadas mediante una red.
ACTIVIDADES POR DESARROLLAR	
1.	Configuración del entorno: Configurar un clúster MPI de tres computadoras (1 nodo máster y 2 nodos hijos) interconectadas mediante una red local, verificando la correcta comunicación entre ellas.
2.	Definición y diseño del problema: Plantear y documentar un problema de NLP a resolver mediante modelos de Machine Learning, indicando objetivo y tipo de datos.
3.	Implementación de la comunicación entre nodos: Implementar comunicación entre nodos usando mpi4py, donde el nodo máster envía el dataset y los parámetros de entrenamiento, y los nodos hijos devuelven los resultados.
4.	Paralelismo interno en cada nodo: Implementar paralelismo local en cada nodo utilizando multiprocessing u otra herramienta similar.
5.	Desarrollo de la GUI: Desarrollar una interfaz gráfica en el nodo máster que visualice la comunicación entre nodos y los modelos ejecutados.
6.	Escritura del informe técnico: Documentar la arquitectura del clúster, las clases y métodos implementados, y los resultados obtenidos. Incluir capturas de pantalla del estado final de la base de datos y los reportes generados. Subir al AVAC el informe del proyecto en formato *.pdf. El informe debe contar con conclusiones apropiadas y la firma de cada estudiante
RESULTADO(S) OBTENIDO(S):	
• Diseña e implementa aplicaciones en paralelo.	
CONCLUSIONES:	
• Los estudiantes podrán interactuar con el análisis y diseño de algoritmos paralelos	
RECOMENDACIONES:	
• Tomar el tiempo de ejecución de cada proceso por separado	

Docente: Ing. Gabriel León Paredes, PhD.



Firma: